

# 5 贝叶斯分类器知识要点

---

## 5 贝叶斯分类器知识要点

### 5.1 本集简介

### 5.2 贝叶斯公式

知识补充

### 5.3 朴素贝叶斯分类器

对最大后验概率的理解

盲点

离散型的随机变量

连续型随机变量

计算MLE

总结朴素贝叶斯分类器

### 5.4 正态贝叶斯分类器

正态贝叶斯分类器

### 5.5 实验

### 5.5 实际应用

### 5.6 本集总结

我的why

## 5.1 本集简介

---

✓ 贝叶斯公式

$$P(C|Z)$$

朴素贝叶斯分类器

预测算法

训练算法

正态贝叶斯分类器

预测算法

训练算法

实验环节



实际应用

## 5.2 贝叶斯公式

随机事件是在[随机试验](#)中，可能出现也可能不出现，而在大量重复试验中具有某种规律性的事件叫做随机事件(简称事件)。随机事件通常用大写[英文字母](#)A、B、C等表示。

果  $\uparrow$  事件  $\rightarrow$  因

$$p(b|a) = \frac{p(a|b)p(b)}{p(a)} \quad p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

$\leftarrow$  60  $\rightarrow$   $= p(a, b)$

最大化后验概率

$$\arg \max_y p(x|y)p(y)$$

随机事件推广到随机变量。

贝叶斯分类器。分类器。

$$P(z|y)$$

$$P(y|z)$$


$$\frac{p(b|a) = p(a|b)p(b)}{p(a)}$$

推广到随机变量

$$\frac{p(y|x) = p(x|y)p(y)}{p(x)}$$

最大化后验概率

$$\arg \max_y p(x|y)p(y)$$



重点理解最大化后验概率

概率密度函数，PDF

什么是先验概率？

条件概率，全概率公式，这些都是要记住的。

例如：男性的脚比女性的脚大。

连续型特征

$\underline{X} = x_1, x_2, \dots, x_n$

$(x_i)$

$$f(x_i = x | y = c) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$\arg \max_c p(y = c) \prod_{i=1}^n f(x_i | y = c)$$

## 知识补充


条件概率

贝叶斯公式

$$p(b|a) = \frac{p(a,b)}{p(a)}$$

$$p(a|b) = \frac{p(a,b)}{p(b)}$$

$$p(a|b) = \frac{p(a)p(b|a)}{p(b)}$$



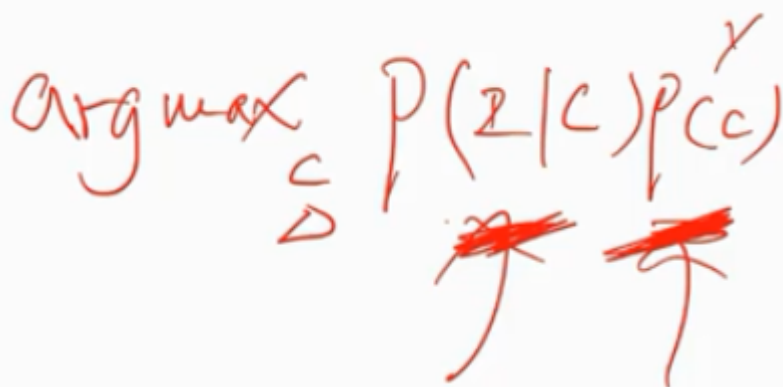
## 5.3 朴素贝叶斯分类器

重点记住这两个公式

朴素贝叶斯分类器

$$p(y = c_i | x) = \frac{p(y = c_i) p(x | y = c_i)}{p(x)}$$


$$p(y = c_i | x) = \frac{p(y = c_i) \prod_{j=1}^n p(x_j | y = c_i)}{Z}$$


$$\operatorname{argmax}_c P(x|c)P(c)^x$$

分为两个部分，一个是离散型随机变量？

怎么根据样本来估计它的PDF？

现实世界中的事件，一般假设服从正态。



## 对最大后验概率的理解

---

### 盲点

独立同分布的**中心极限定理**。

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} \left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt = \Phi(x)$$

## 离散型的随机变量

---

离散型特征

$$p(x_j = v | y = c) = \frac{\sum N_{x_{ij}=v \wedge y_i=c}}{N_{y=c}}$$

$$\arg \max_y p(y=c) \prod_{j=1}^n p(x_j = v | y = c)$$

$$p(x_j = v | y = c) = \frac{\sum N_{x_{ij}=v \wedge y_i=c} + 1}{N_{y=c} + k}$$

离散型特征  
类条件概率

$$p(x_i = v | y = c) = \frac{N_{x_i=v, y=c}}{N_{y=c}}$$

类概率

$$p(y = c) = \frac{N_{y=c}}{N}$$

预测函数

$$\arg \max_y p(y = c) \prod_{i=1}^n p(x_i = v | y = c)$$

拉普拉斯平滑

$$p(x_i = v | y = c) = \frac{N_{x_i=v \wedge y=c} + 1}{N_{y=c} + k}$$

$x_2 \rightarrow$  有限

$P(x_2 = x | c)$

	$x_1$	$x_2$	$x_n$
1			
2			
$\vdots$			
$\vdots$			
$\vdots$			
$\vdots$			

$x_i = 0.1$

$\frac{6}{10}$        $\frac{4}{10}$

$P(x_1 = 0 | c) = 0.6$

0.4

分母，分子

$$p(x_j = v | y = c) = \frac{\sum N_{x_{ij} = v \wedge y_i = c}}{N_{y=c}}$$

有一个问题是，分母可能为零。所以要在分母上加一个k，分子加上1

$$p(x_j = v | y = c) = \frac{\sum N_{x_{ij} = v \wedge y_i = c} + 1}{N_{y=c} + k}$$



## 连续型随机变量

连续型特征

$$f(x_i = x | y = c) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$\arg \max_c p(y = c) \prod_{i=1}^n f(x_i | y = c)$$

如果是连续的，假设服从正态分布

## 计算MLE

最大似然估计

Handwritten notes for Maximum Likelihood Estimation (MLE) of a normal distribution:

$c: l$

$(\mu, \sigma^2)$

MLE


$\mu = \frac{1}{l} \sum_{i=1}^l x_i$

$\sigma^2 = \frac{1}{l} \sum_{i=1}^l (x_i - \mu)^2$

mu和sigma 算出来

## 总结朴素贝叶斯分类器

假设分量 $x_1, x_2, \dots, x_n$ 相互独立。




## 5.4 正态贝叶斯分类器

多维正态分布

MB

$$p(\mathbf{x}|\mathbf{c}) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)\right)$$



多维正态分布

多维正态分布

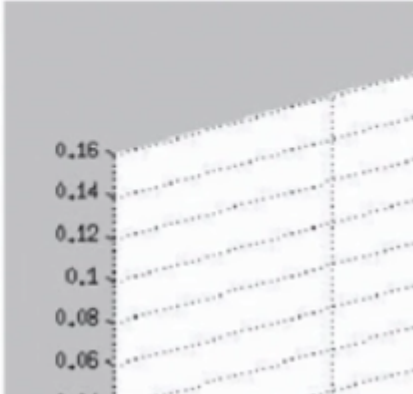
NB  $\rightarrow \frac{1}{\sigma^2}$

$$p(x|c) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

$\sqrt{|\Sigma|}$

$\frac{\varphi}{2}$

2



$p(x)$

最大似然估计

## 正态贝叶斯分类器

正态贝叶斯分类器

$$p(x|c) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

$$\Sigma = U W U^T$$

$$(\Sigma)^{-1} = (U W U^{-1})^{-1} = U W^{-1} U^{-1} = U W^{-1} U^T$$

$$\arg \max_c (p(c|x)) = \arg \max_c \left( \frac{p(c) p(x|c)}{p(x)} \right)$$

$$\arg \max_c (p(x|c))$$

$$\ln(p(x|c)) = \ln\left(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}}\right) - \frac{1}{2} ((x-\mu)^T \Sigma^{-1} (x-\mu))$$

$$\ln(p(x|c)) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} ((x-\mu)^T \Sigma^{-1} (x-\mu)) \quad \ln(|\Sigma|) + ((x-\mu)^T \Sigma^{-1} (x-\mu))$$

$$p(\mathbf{x}|c) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right)$$

$$\Sigma = \mathbf{U}\mathbf{W}\mathbf{U}^T$$

$$(\Sigma)^{-1} = (\mathbf{U}\mathbf{W}\mathbf{U}^{-1})^{-1} = \mathbf{U}\mathbf{W}^{-1}\mathbf{U}^{-1} = \mathbf{U}\mathbf{W}^{-1}\mathbf{U}^T$$

协方差矩阵

实对称矩阵

带到贝叶斯分类器

$$\arg \max_c (p(c|\mathbf{x})) = \arg \max_c \left( \frac{p(c)p(\mathbf{x}|c)}{p(\mathbf{x})} \right)$$

$$\arg \max_c (p(\mathbf{x}|c))$$

奇异值分解

$$\ln(p(\mathbf{x}|c)) = \ln\left(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}}\right) - \frac{1}{2}((\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu))$$

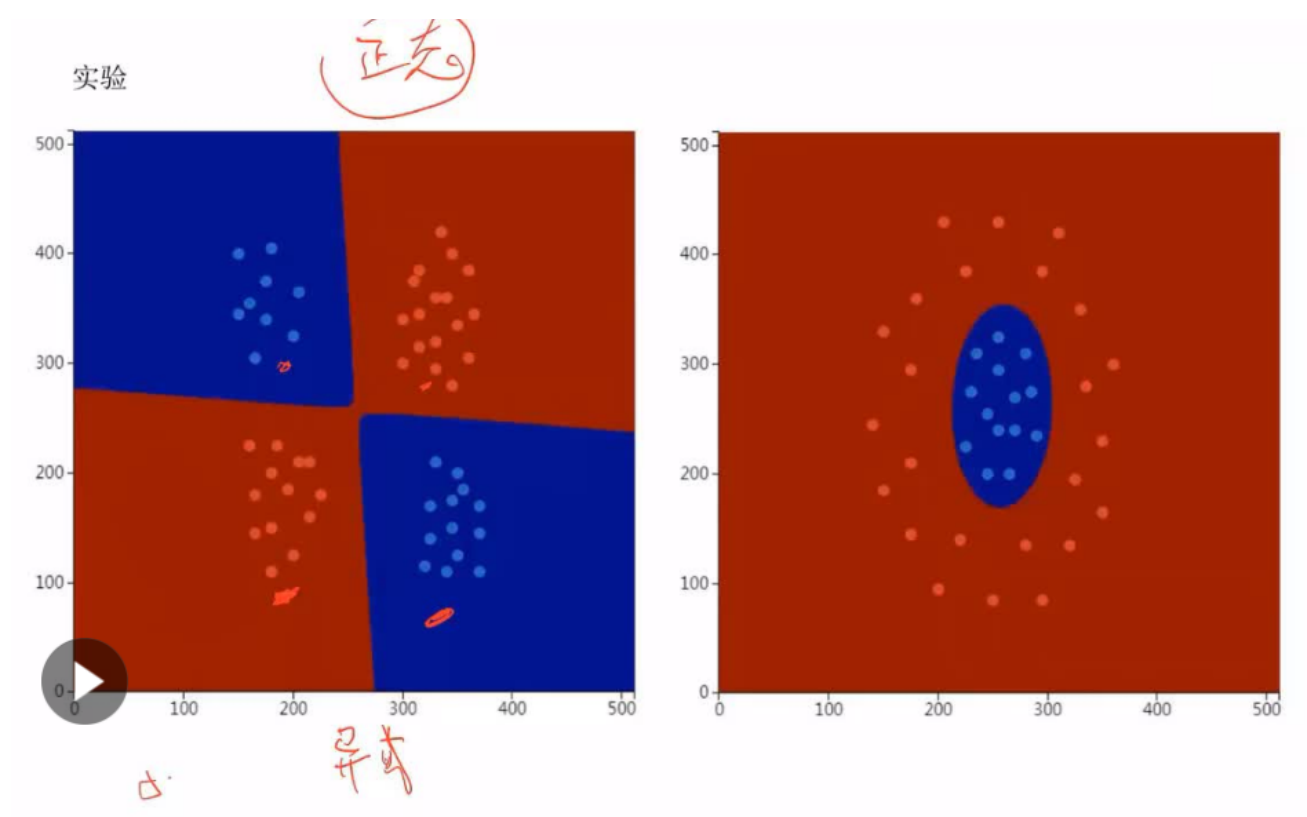
$$\ln(p(\mathbf{x}|c)) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln(|\Sigma|) - \frac{1}{2}((\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)) \quad \ln(|\Sigma|) + ((\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu))$$

正态贝叶斯分类器，

$$\begin{pmatrix} \mu \\ \Sigma \end{pmatrix}$$

$$\ln(|\Sigma|) + ((\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu))$$


## 5.5 实验



实验环节

贝叶斯分类器有非线性的模型。

点击打开训练集



## 5.5 实际应用

应用

垃圾邮件分类问题

Mehran Sahami, Susan T Dumais, David Heckerman, Eric Horvitz. A Bayesian Approach to Filtering Junk E-Mail. 1998.

文本分类问题

Yiming Yang, Xin Liu. A re-examination of text categorization methods. international acm sigir conference on research and development in information retrieval, 1999.

智能视频监控中的背景建模算法

Liyuan Li, Weimin Huang, Irene Y H Gu, Qi Tian. Foreground object detection from videos containing complex background. acm multimedia, 2003.

人脸识别中的联合贝叶斯模型

Dong Chen, Xudong Cao, Liwei Wang, Fang Wen, Jian Sun. Bayesian face revisited: a joint formulation. european conference on computer vision, 2012.

- 垃圾邮件分类
- 文本分类问题
  - TF-IDF 比如分
- 智能视频监控中的背景建模算法
  - 判断图片是全景还是背景，是个二分类问题
- 人脸识别中的联合贝叶斯模型


判断是全景还是

$$P(C|\mathbf{v}_t, s) = \frac{P(\mathbf{v}_t|C, s)P(C|s)}{P(\mathbf{v}_t|s)}, \quad C = b \text{ or } f$$

$$P(b|\mathbf{v}_t, s) > P(f|\mathbf{v}_t, s)$$

$$P(\mathbf{v}_t|s) = P(\mathbf{v}_t|b, s) \cdot P(b|s) + P(\mathbf{v}_t|f, s) \cdot P(f|s)$$

$$2P(\mathbf{v}_t|b, s) \cdot P(b|s) > P(\mathbf{v}_t|s)$$



$$P(C|\mathbf{v}_t, s) = \frac{P(\mathbf{v}_t|C, s)P(C|s)}{P(\mathbf{v}_t|s)}, \quad C = b \text{ or } f$$

$$P(b|\mathbf{v}_t, s) > P(f|\mathbf{v}_t, s) \rightarrow b$$

$$P(\mathbf{v}_t|s) = P(\mathbf{v}_t|b, s) \cdot P(b|s) + P(\mathbf{v}_t|f, s) \cdot P(f|s)$$

$$2P(\mathbf{v}_t|b, s) \cdot P(b|s) > P(\mathbf{v}_t|s)$$

## 5.6 本集总结

1. 贝叶斯公式

2. Naive Bayes  
Normal Bayes

MAP  $P(c|x)$

$\arg \max_c P(c) P(x|c)$

1. 贝叶斯公式
2. Bayes, 正态贝叶斯
3. 实验的环节

自我总结：这节课的知识挺难的，涉及到的知识面也是比较广。

## 我的why

为什么朴素贝叶斯是“朴素”的？

**Answer：**“朴素”是因为它假设了数据集中的**所有特征是同等重要的并且是条件独立的**。然而，这是一个很强的假设，在实际情况中，这个假设通常很难严格成立。

**Q5：解释朴素贝叶斯算法中的先验概率、似然和边缘似然概念？**

**Answer：****\*\*先验概率\*\***代表了数据集中因变量的比例，它是指你不依靠额外的信息能做出最有可能的类别猜测。比如，在一个垃圾邮件分类的数据集中，因变量是二进制的（0和1），1（垃圾邮件）的比例是70%而0（非垃圾邮件）的比例是30%，据此，我们可以估计一个新的邮件有70%的可能是垃圾邮件。

似然是指存在其他变量的情况下，把一个给定的观测分类为1的概率。比如，“FREE”这个词出现在垃圾邮件中的概率就是似然。**边缘似然是“FREE”出现在任何邮件中的概率。**