

9 数据降维2--非线性降维

9 数据降维2--非线性降维

9.1 本集内容简介

9.2 非线性降维技术简介

9.3 流行简介

什么是流行？

9.4 流行学习简介

9.5 局部线性嵌入

9.6 拉普拉斯的特征映射

图

拉普拉斯矩阵半正定

算法流程

9.7 局部保持投影

9.8 等距映射

什么是测地线？

9.9 实验环节

9.10 本集总结

9.1 本集内容简介

非线性降维算法

流形的概念

流形学习的概念

局部线性嵌入

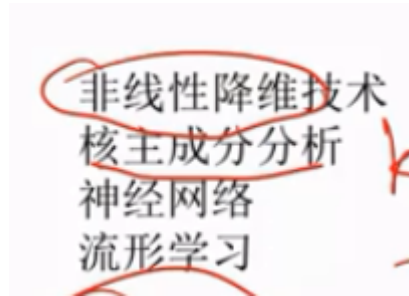
拉普拉斯特征映射

局部保持投影

等距映射

实验环节


9.2 非线性降维技术简介



这节课的重点是流形学习算法

9.3 流形简介


什么是流形？



在微分几何和拓扑里面

就是空间中，有一个类似集合形状的东西。

三维空间里的一个例子



9.4 流行学习简介

什么是流形学习？

假设数据在高维空间中的分布服从某种几何形状

利用这种几何约束来完成对数据的处理，如降维，分类，聚类

局部线性嵌入

[1] Roweis, Sam T and Saul, Lawrence K. Nonlinear dimensionality reduction by locally linear embedding. Science, 290(5500). 2000: 2323-2326.

拉普拉特征映射

[2] Belkin, Mikhail and Niyogi, Partha. Laplacian eigenmaps for dimensionality reduction and data representation. Neural computation. 15(6). 2003:1373-1396.

局部保持投影

[3] He Xiaofei and Niyogi, Partha. Locality preserving projections. NIPS. 2003:234-241.

等距映射

[4] Tenenbaum, Joshua B and De Silva, Vin and Langford, John C. A global geometric framework for nonlinear dimensionality reduction. Science, 290(5500). 2000: 2319-2323.

有兴趣可以看论文

9.5 局部线性嵌入

局部线性嵌入 (LLE)

每个样本可以用它邻居的线性组合近似重构： $\mathbf{x}_i \approx \sum_j w_{ij} \mathbf{x}_j$

求解下面的最优化问题可以得到重构系数：

$$\varepsilon(W) = \sum_i \left\| \mathbf{x}_i - \sum_j w_{ij} \mathbf{x}_j \right\|^2$$

$$\sum_j w_{ij} = 1$$

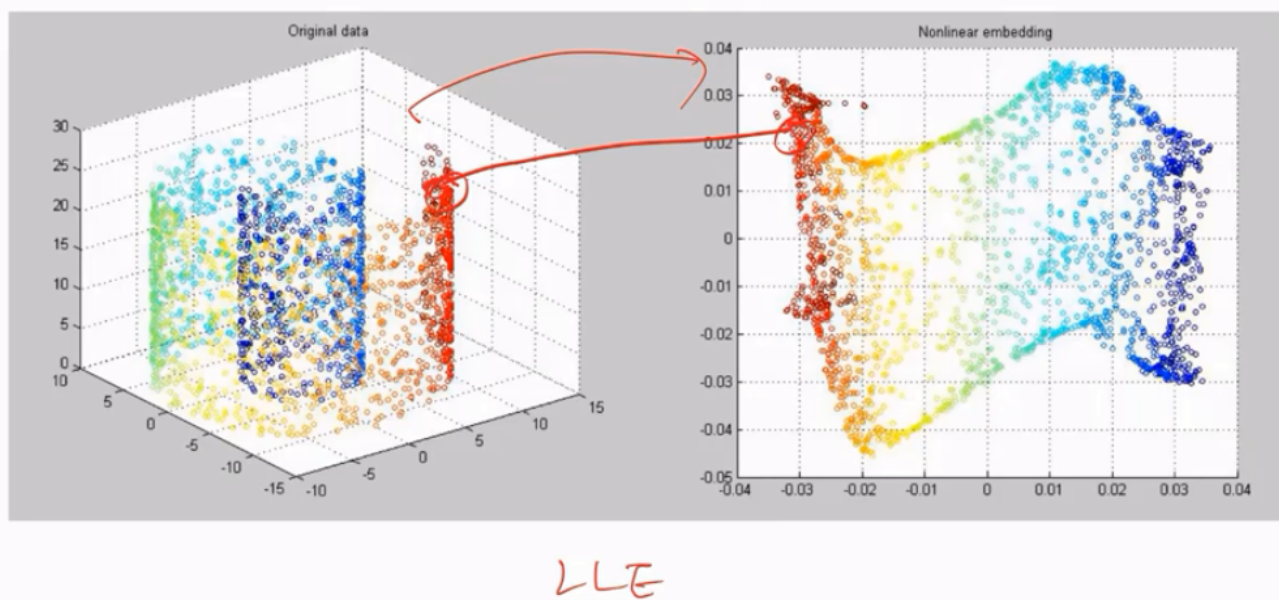
将向量映射到低维空间，保持这种线性重构关系：

$$\Phi(Y) = \sum_i \left\| \mathbf{y}_i - \sum_j w_{ij} \mathbf{y}_j \right\|^2$$

1. 简写LLE

1. 核心思想

2. 公式很难记住



9.6 拉普拉斯的特征映射

拉普拉斯特征映射 基于图论的方法

用样本构造图，然后计算拉普拉斯矩阵，最后对矩阵进行特征值分解

1. 计算拉普拉斯矩阵
2. 对矩阵进行特征值分解


图

$\langle V, E, W \rangle$

- V 定点
- E 边
- W 权重

图

顶点，边，权重
有向图，无向图
邻接矩阵
度，加权重



邻接矩阵

$$\begin{bmatrix} 0 & 1 & 3 & 0 & 0 \\ 1 & 0 & 2 & 5 & 0 \\ 3 & 2 & 0 & 0 & 0 \\ 0 & 5 & 0 & 0 & 3 \\ 0 & 0 & 0 & 3 & 0 \end{bmatrix}$$

加权重矩阵 $d_i = \sum_j w_{ij}$

$$\begin{bmatrix} 4 & 0 & 0 & 0 & 0 \\ 0 & 8 & 0 & 0 & 0 \\ 0 & 0 & 5 & 0 & 0 \\ 0 & 0 & 0 & 8 & 0 \\ 0 & 0 & 0 & 0 & 3 \end{bmatrix}$$

拉普拉斯矩阵

$$L = D - W$$

$$\begin{bmatrix} 4 & -1 & -3 & 0 & 0 \\ -1 & 8 & -2 & -5 & 0 \\ -3 & -2 & 5 & 0 & 0 \\ 0 & -5 & 0 & 8 & -3 \\ 0 & 0 & 0 & -3 & 3 \end{bmatrix}$$



- D：加权重矩阵，把相邻边的权重加起来
- W：邻接矩阵，主对角线上都是0
- L：拉普拉斯矩阵

拉普拉斯矩阵半正定

注意公式推导做了拆分

拉普拉斯矩阵半正定

$$L = D - W$$

$$f^T L f = f^T D f - f^T W f$$

$$= \sum_{i=1}^n d_i f_i^2 - \sum_{i=1}^n \sum_{j=1}^n w_{ij} f_i f_j$$

$$= \frac{1}{2} \left(\sum_{i=1}^n d_i f_i^2 - 2 \sum_{i=1}^n \sum_{j=1}^n w_{ij} f_i f_j + \sum_{j=1}^n d_j f_j^2 \right)$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (f_i - f_j)^2$$

算法流程

有了以上基础之后

算法流程

构造带权重的图

计算图的拉普拉斯矩阵

求解广义特征值问题


构造带权重的图

$$\|x_i - x_j\|^2 < \varepsilon$$

近邻规则

计算权重


$$w_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{t}\right)$$



怎么判断图的连通性

$$\|x_i - x_j\|^2 < \varepsilon$$

近邻规则



特征映射这部分注意推导

特征映射

$$Lf = \lambda Df$$

$$0 = \lambda_0 \leq \dots \leq \lambda_{k-1}$$

$$f_0, \dots, f_{k-1}$$

$$V \quad E \quad W \quad \Delta \rightarrow D \quad \Delta$$

$$L = D - W$$

$$\begin{bmatrix} \sigma_1 I \\ \sigma_2 I \\ \vdots \\ \sigma_k I \end{bmatrix} \quad \begin{bmatrix} L = D - W \\ \vdots \end{bmatrix}$$

处理特征值问题

9.7 局部保持投影

局部保持投影也是基于图论的算法。

局部保持投影

$$XLX^T \mathbf{a} = \lambda XDX^T \mathbf{a}$$

$$\lambda_0 < \dots < \lambda_{l-1}$$

$$\mathbf{a}_0, \dots, \mathbf{a}_{l-1}$$

$$\mathbf{x}_i \rightarrow \mathbf{y}_i = A^T \mathbf{x}_i, A = (\mathbf{a}_0, \mathbf{a}_1, \dots, \mathbf{a}_{l-1})$$

拉普拉斯的映射和PCA是一样的

9.8 等距映射

等距映射

利用了测地线的概念

将数据投影到低维空间之后，尽量保持原有的距离关系

什么是测地线？

什么是测地线？

例如美国和中国远，



拿地图做例子



- 以前高中几何，球面上两点最短的距离是弧长。

首先构造图


然后计算两点间的最短距离-Dijkstra算法

$$D_G = \{d_G(i, j)\}$$

然后求解下面的最优化问题：

$$\min_y \sum_{i=1}^N \sum_{j=1}^N \left(d_G(i, j) - \|y_i - y_j\| \right)^2$$

迪杰特斯拉算法




总结：

- 计算图
- 计算测地线
- 求解最优化问题，保持相对距离

9.9 实验环节

在云端实验室

这节课所学的算法都有



流行学算法，2000年诞生之后，挺火热的。但是很少有实际的应用。

9.10 本集总结

