

10 线性判别分析

10 线性判别分析

10.1 本集内容简介

10.2 LDA的基本思想

10.3 寻找最佳投影方向

类间散步

类内散步

类间散步

类内散步矩阵

优化目标有冗余

10.4 推广到高维和多类的情况

10.5 PCA与LDA的比较

10.6 实验环节


10.7 实际应用

用PCA和LDA作人脸识别

10.8 本集总结

10.1 本集内容简介

LDA的思想
寻找最佳投影方向
推广到高维
与PCA的比较
实验环节
实际应用



10.2 LDA的基本思想

流行学习和监督学习

阐述思想

主成分分析，流形降维算法都是无监督学习，整个计算过程中没有利用样本标签值，它们投影的结果对分类未必有利

能不能有一种算法，对数据投影之后，能够更便于分类？

分类要达成的目标

区分不同的类，同一类的样本特征要尽量相似；不同类之间要尽可能不同


线性判别分析就是达成这种目标的一种线性算法

最大化类间差异，最小化类内差异

投影到一维空间，在图中，类间的差异最大化了。


同类样本投影后聚集在一起
不同类样本离得尽可能远

$$y = w^T x$$



两个类间的距离被最大化了。

图中竖线的投影效果就不好。类之间有重叠。



10.3 寻找最佳投影方向

问题的关键是如何得到最佳投影矩阵
首先考虑一维的情况

整个样本集 $\mathbf{x}_i \quad n$

分属两个类 $C_1 \quad D_1 \quad n_1 \quad C_2 \quad D_2$

向一维空间投影 $y = \mathbf{w}^T \mathbf{x}$

投影后得到两组标量 $Y_1 \quad Y_2$

类间差异用两个类的均值之差来衡量-类间散布
类内差异用方差来衡量-类内散布

- 均值
- 方差

分两步进行，

先一维，再到多维。

问题的关键是如何得到最佳投影矩阵
首先考虑一维的情况

$$Y = W^T X \quad PCA \quad \begin{matrix} 1. 1d \\ 2. \sum d \end{matrix}$$

整个样本集 x_i n x_1, x_2, \dots, x_n

分属两个类 C_1 D_1 n_1 C_2 D_2 n_2

向一维空间投影 $y = w^T x$

投影后得到两组标量 Y_1 Y_2

类间差异用两个类的均值之差来衡量-类间散布
类内差异用方差来衡量-类内散布



$$\begin{aligned} u_1 + u_2 &= u \\ C_1, C_2 \\ D_1, D_2 &= D \end{aligned}$$

类间散步

类间散布

$$\mathbf{m}_i = \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{x}$$

$$\tilde{\mathbf{m}}_i = \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{w}^T \mathbf{x} = \mathbf{w}^T \mathbf{m}_i$$

$$|\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2| = |\mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2)|$$

类内散布

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{\mathbf{m}}_i)^2$$

总类内散布

$$\tilde{s}_1^2 + \tilde{s}_2^2$$

优化目标

$$L(\mathbf{w}) = \frac{(\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2}$$

投影到

类内散布

类内散布

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{\mathbf{m}}_i)^2$$

总类内散布

$$\tilde{s}_1^2 + \tilde{s}_2^2$$

优化目标

$$L(\mathbf{w}) = \frac{(\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2}$$

用方差来描述，但是没有取平均。

类间散布

类内散布矩阵

$$S_i = \sum_{x \in D_i} (x - m_i)(x - m_i)^T$$

$$S_W = S_1 + S_2$$

$$\begin{aligned}\tilde{s}_i^2 &= \sum_{x \in D_i} (w^T x - w^T m_i)^2 \\ &= \sum_{x \in D_i} w^T (x - m_i)(x - m_i)^T w \\ &= w^T S_i w\end{aligned}$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = w^T S_W w$$

两个类的散布矩阵之和

类内散步矩阵

类间散步矩阵公式

$$(\tilde{m}_1 - \tilde{m}_2)^2 = (w^T (m_1 - m_2))^2 = w^T (m_1 - m_2)(m_1 - m_2)^T w$$

$$S_B = (m_1 - m_2)(m_1 - m_2)^T$$

$$(\tilde{m}_1 - \tilde{m}_2)^2 = w^T S_B w$$

优化目标变为

$$L(w) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2} \qquad L(w) = \frac{w^T S_B w}{w^T S_W w}$$

优化目标有冗余

优化目标有冗余

$$L(w) = \frac{w^T S_B w}{w^T S_W w}$$

为了消掉冗余，加上一个约束条件

$$w^T S_W w = 1$$

优化的目标变为

$$\begin{aligned} \max w^T S_B w \\ w^T S_W w = 1 \end{aligned}$$

优化目标函数用拉格朗日乘数法来求解。

用拉格朗日乘数法求解

$$L = w^T S_B w + \lambda (w^T S_W w - 1)$$

$$S_B w + \lambda S_W w = 0$$

$$S_B w = -\lambda S_W w \quad S_W^{-1} S_B w = -\lambda w$$

对lambda 和 w 求导

$$\nabla_{\mathbf{x}} (\mathbf{x}^T \mathbf{A} \mathbf{x}) = 2\mathbf{A}\mathbf{x}$$

类间散布矩阵的秩小于等于1

$$\mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} = \lambda \mathbf{w}$$

上面这个矩阵的秩也小于等于1

$$\text{rank}(\mathbf{S}_B) \leq 1$$

10.4 推广到高维和多类的情况

推广到高维

类内散布矩阵

$$\mathbf{S}_i = \sum_{\mathbf{x} \in D_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T$$

$$\mathbf{S}_W = \sum_{i=1}^c \mathbf{S}_i$$

类间散布矩阵

$$\mathbf{S}_B = \sum_{i=1}^c n_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T$$

优化目标

$$\max L(\mathbf{W}) = \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_B \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_W \mathbf{W})}$$

$$\mathbf{S}_B \mathbf{w}_i = \lambda_i \mathbf{S}_W \mathbf{w}_i$$

$$\mathbf{y} = \mathbf{W}^T \mathbf{x}$$

10.5 PCA与LDA的比较

与PCA的比较

二者都是求解特征值问题

LDA是有监督学习，PCA是无监督学习


投影的目标不同，LDA是最大化类间差异，最小化类内差异；PCA是最小化重构误差

面临的问题

内类散布矩阵不可逆

10.6 实验环节

云端实验室实验运行结果



黑色是一类，白色是一类。找到了最佳决策边界，验证了LDA是线性的。

代码通过c++实现

C++
Bayes
DT
KNN
LDA

10.7 实际应用

人脸识别

- [1] Matthew Turk, Alex Pentland. Eigenfaces for recognition. Journal of Cognitive Neuroscience, 1991.
- [2] Peter N Belhumeur J P Hespanha David Kriegman. Eigenfaces vs. Fisherfaces, recognition using class specific linear projection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997.

LDA一般先做降维，作用其他的算法做分类。

用PCA和LDA作人脸识别




假设是一个 32×32 的矩阵，放到一维向量1024。

$$10 \times 10 = 100$$

每一行是一个特征点。

先通过PCA降维，再通过LDA降维，



##

10.8 本集总结

1. LDA
2. $\int \text{ld} \rightarrow \odot \rightarrow \left(\frac{\odot}{\odot} \right) \rightarrow \text{max}$
3. LDA VS PCA

回顾本章，主要讲的是LDA算法，重点在寻找最佳投影方向，这部分用的公式比较多。

要记住，LDA最大化类间差异，最小化类内差异。PCA是最小化重构误差。