

15 支持向量机2

15 支持向量机2

15.1 本集内容简介

15.2 对偶问题求解面临的问题

15.3 SMO算法简介

15.4 求解子问题

15.5 子问题是凸优化问题的证明

15.6 SMO算法的收敛性

15.7 优化变量的选择

求出 α_j

15.8 完整的算法

15.9 实现细节问题

15.10 本集总结

15.1 本集内容简介

上节课三种情况，线性可分，线性不可分，

为什么使用SMO算法

SVM求解面临的问题
SMO算法简介
子问题的求解
子问题是凸优化的证明
收敛性的保证
优化变量的选择
完整的算法
实现细节问题

15.2 对偶问题求解面临的问题

SVM求解面临的问题
问题的规模等于训练样本数
计算速度
存储空间
带有约束条件

正定二次型？

回忆SVM的对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(x_i^T x_j) - \sum_{k=1}^l \alpha_k$$

$$0 \leq \alpha_i \leq C$$

$$\sum_{j=1}^l \alpha_j y_j = 0$$

$$\min_{\alpha} \frac{1}{2} \alpha^T Q \alpha - e^T \alpha$$

$$y^T \alpha = 0$$

$$0 \leq \alpha_i \leq C, i = 1, \dots, l$$

1x1

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(x_i^T x_j) - \sum_{k=1}^l \alpha_k$$

$$0 \leq \alpha_i \leq C$$

$$\sum_{j=1}^l \alpha_j y_j = 0$$

$$\min_{\alpha} \frac{1}{2} \alpha^T Q \alpha - e^T \alpha$$

$$y^T \alpha = 0$$

$$0 \leq \alpha_i \leq C, i = 1, \dots, l$$

二次规划

15.3 SMO算法简介

SMO算法简介

Sequential minimal optimization, 顺序最小优化

Platt等人于1998年提出

核心思想是分治法, 每次挑选出两个变量进行优化

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j) \quad K_{ij} = K(x_i, x_j)$$

$$Q_{ij} = y_i y_j K(x_i, x_j) \quad Q_{ij} = y_i y_j K_{ij}$$

$$u_i = \sum_{j=1}^l y_j \alpha_j K(x_j, x_i) - b$$

$$\begin{aligned} \text{最优点处必须满足} \quad & \alpha_i = 0 \Leftrightarrow y_i u_i \geq 1 \\ & 0 < \alpha_i < C \Leftrightarrow y_i u_i = 1 \\ & \alpha_i = C \Leftrightarrow y_i u_i \leq 1 \end{aligned}$$

下图中

图中举行方框的等式约束, 如果 α_i 调整不等于0。

最少要挑选两个变量来优化。

SVM求解面临的问题

问题的规模等于训练样本数

计算速度

存储空间

带有约束条件

$Q: L \times L$

$1w \times 1w$

$L \times L$

$\min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(x_i^T x_j) - \sum_{k=1}^l \alpha_k$

$0 \leq \alpha_i \leq C$

$\sum_{j=1}^l \alpha_j y_j = 0$

$\min_{\alpha} \frac{1}{2} \alpha^T Q \alpha - e^T \alpha$

$y^T \alpha = 0$

$0 \leq \alpha_i \leq C, i=1, \dots, l$

SMO

1×2

a_i

$1w \rightarrow 1d \rightarrow 10, 100$

$= 1 \times 100$

再来看变量的定义

- 定义核矩阵
- 定义Q
- 定义ui

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

$$K_{ij} = K(x_i, x_j)$$

$$Q_{ij} = y_i y_j K(x_i, x_j)$$

$$Q_{ij} = y_i y_j K_{ij}$$

$$u_i = \sum_{j=1}^l y_j \alpha_j K(x_j, x_i) - b$$

最优点处必须满足

$$\alpha_i = 0 \Leftrightarrow y_i u_i \geq 1$$

$$0 < \alpha_i < C \Leftrightarrow y_i u_i = 1$$

$$\alpha_i = C \Leftrightarrow y_i u_i \leq 1$$

15.4 求解子问题

两个变量子问题

$$f(\alpha_i, \alpha_j) = \frac{1}{2}K_{ii}\alpha_i^2 + \frac{1}{2}K_{jj}\alpha_j^2 + sK_{ij}\alpha_i\alpha_j + y_iv_i\alpha_i + y_jv_j\alpha_j - \alpha_i - \alpha_j + c$$


$$s = y_i y_j$$

$$v_i = \sum_{k=1, k \neq i, k \neq j}^l y_k a_k^* K_{ik}$$

$$0 \leq \alpha_i \leq C$$


$$0 \leq \alpha_j \leq C$$

$$y_i \alpha_i + y_j \alpha_j = - \sum_{k=1, k \neq i, k \neq j}^l y_k \alpha_k = \xi$$



$$L = \max(0, \alpha_j - \alpha_i)$$

$$H = \min(C, C + \alpha_j - \alpha_i)$$



$$L = \max(0, \alpha_j + \alpha_i - C)$$

$$H = \min(C, \alpha_j + \alpha_i)$$

前面讲到的，

两个变量问题

$(2i, 2j) \rightarrow 1$

$$f(\alpha_i, \alpha_j) = \frac{1}{2}K_{ii}\alpha_i^2 + \frac{1}{2}K_{jj}\alpha_j^2 + sK_{ij}\alpha_i\alpha_j + y_iv_i\alpha_i + y_jv_j\alpha_j - \alpha_i - \alpha_j + c$$

$$s = y_i y_j$$

$$v_i = \sum_{k=1, k \neq i, k \neq j}^l y_k a_k^* K_{ik}$$

$$0 \leq \alpha_i \leq C$$

$$0 \leq \alpha_j \leq C$$

$$y_i \alpha_i + y_j \alpha_j = - \sum_{k=1, k \neq i, k \neq j}^l y_k \alpha_k = \xi$$


$+1 +1$

$2i$




$2j$

1222

$\frac{1}{2} \alpha_i - e^2$



$$\alpha_j^{\text{new}} = \begin{cases} H & \alpha_j^{\text{new, unclipped}} > H \\ \alpha_j^{\text{new, unclipped}} & L \leq \alpha_j^{\text{new, unclipped}} \leq H \\ L & \alpha_j^{\text{new, unclipped}} < L \end{cases}$$



$f(\alpha_j) \rightarrow \infty$
 $[L, H]$

$$\alpha_i + y_i y_j \alpha_j = y_i \xi \quad \alpha_i = y_i \xi - y_i y_j \alpha_j$$

$$w = y_i \xi$$

$$\frac{1}{2} K_{ii} (w - s \alpha_j)^2 + \frac{1}{2} K_{jj} \alpha_j^2 + s K_{ij} (w - s \alpha_j) \alpha_j + y_i v_i (w - s \alpha_j) + y_j v_j \alpha_j - (w - s \alpha_j) - \alpha_j + c$$

求导并令导数为0


$$K_{ii} (w - s \alpha_j) (-s) + K_{jj} \alpha_j + s K_{ij} (w - 2s \alpha_j) - s y_i v_i + y_j v_j + s - 1 = 0$$

$$s y_i v_i = y_i y_j y_i v_i = y_j v_i$$

$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j - s w K_{ii} - s w K_{ij} - y_j v_i + y_j v_j + s - 1 = 0$$

$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j = s w (K_{ii} + K_{ij}) + y_j v_i - y_j v_j + 1 - s$$

$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j = \alpha_j^* (K_{ii} + K_{jj} - 2K_{ij}) + y_j (u_i - u_j + y_j - y_i)$$



$$\alpha_j^{new,clipped} = \begin{cases} H & \alpha_j^{new} > H \\ \alpha_j^{new} & L \leq \alpha_j^{new} \leq H \\ L & \alpha_j^{new} < L \end{cases}$$

$$\alpha_i^{new} = \alpha_i + s(\alpha_j - \alpha_j^{new,clipped})$$


15.5 子问题是凸优化问题的证明

子问题是一个凸优化问题

$$\begin{bmatrix} Q_{ii} & Q_{ij} \\ Q_{ji} & Q_{jj} \end{bmatrix}$$

$$\begin{bmatrix} y_i \mathbf{x}_i^T \\ y_i \mathbf{x}_i^T \end{bmatrix} [y_i \mathbf{x}_i, y_i \mathbf{x}_j] = \mathbf{A}^T \mathbf{A}$$

前面说，抛物线是开口向上的。



是一个凸优化问题，对于一个二元二次矩阵，它的汉森矩阵是正定的。

根据Q的定义，

$$Q_{ij} = \gamma_i \gamma_j (x_i^T x_j)$$

写成矩阵的形式

$$\begin{bmatrix} y_i x_i^T \\ y_j x_j^T \end{bmatrix} \begin{bmatrix} y_i x_i & y_j x_j \end{bmatrix} = A^T A$$

等价于核函数的映射。

支持向量机，是一个凸优化问题。

15.6 SMO算法的收敛性

收敛性的保证

无论本次迭代时两个变量的初始值是多少，通过上面的子问题求解算法得到是在可行域里的最小值，因此每次求解更新这两个变量的值之后，都能保证目标函数值小于或者等于初始值，即函数值下降，所以SMO算法能保证收敛

15.7 优化变量的选择

优化变量的选择

$$\alpha_i = 0 \Leftrightarrow y_i g(x_i) \geq 1$$

$$0 < \alpha_i < C \Leftrightarrow y_i g(x_i) = 1$$

$$\alpha_i = C \Leftrightarrow y_i g(x_i) \leq 1$$

$$g(x_i) = \sum_{j=1}^l \alpha_j y_j K(x_i, x_j) + b$$

$$0 < \alpha_i < C$$

$$|E_i - E_j|$$

$$\alpha_i \quad \alpha_j$$

核心问题是找出 α_i 和 α_j

$$\alpha_i \quad \alpha_j$$

在最优解的时候，必须满足KKT条件

优化变量的选择

$$\alpha_i = 0 \Leftrightarrow y_i g(x_i) \geq 1$$

$$0 < \alpha_i < C \Leftrightarrow y_i g(x_i) = 1$$

$$\alpha_i = C \Leftrightarrow y_i g(x_i) \leq 1$$

KKT

反过来说，如果还没有满足KKT条件，那么就是还没有达到最优解。

$$g(x_i) = \sum_{j=1}^l \alpha_j y_j K(x_i, x_j) + b$$

把xi 带进

优化变量的选择

$$\alpha_i = 0 \Leftrightarrow y_i g(x_i) \geq 1$$
$$0 < \alpha_i < C \Leftrightarrow y_i g(x_i) = 1$$
$$\alpha_i = C \Leftrightarrow y_i g(x_i) \leq 1$$

kkT

求出alpha i.

求出alpha j

这是在前面求解子问题时推导的

$(x_i, y_i) \sim 1$

$$\alpha_i + y_i y_j \alpha_j = y_i \xi \rightarrow \alpha_i = y_i \xi - y_i y_j \alpha_j$$
$$w = y_i \xi$$
$$\frac{1}{2} K_{ii} (w - s \alpha_j)^2 + \frac{1}{2} K_{jj} \alpha_j^2 + s K_{ij} (w - s \alpha_j) \alpha_j + y_i v_i (w - s \alpha_j) + y_j v_j \alpha_j - (w - s \alpha_j) - \alpha_j + c$$

求导并令导数为0

$$K_{ii} (w - s \alpha_j) (-s) + K_{jj} \alpha_j + s K_{ij} (w - 2s \alpha_j) - s y_i v_i + y_j v_j + s - 1 = 0$$
$$s y_i v_i = y_i y_j y_i v_i = y_j v_i$$
$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j - s w K_{ii} - s w K_{ij} - y_j v_i + y_j v_j + s - 1 = 0$$
$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j = s w (K_{ii} + K_{ij}) + y_j v_i - y_j v_j + 1 - s$$
$$(K_{ii} + K_{jj} - 2K_{ij}) \alpha_j = \alpha_i^* (K_{ii} + K_{jj} - 2K_{ij}) + y_j (u_i - u_j + y_j - y_i)$$
$$\eta = K_{ii} + K_{jj} - 2K_{ij}$$
$$\alpha_j^{new} = \alpha_j + \frac{y_j (E_i - E_j)}{\eta}$$
$$E_i = u_i - y_i$$

x_i

这里要让

$$|E_i - E_j|$$

的绝对值最大化，
找出

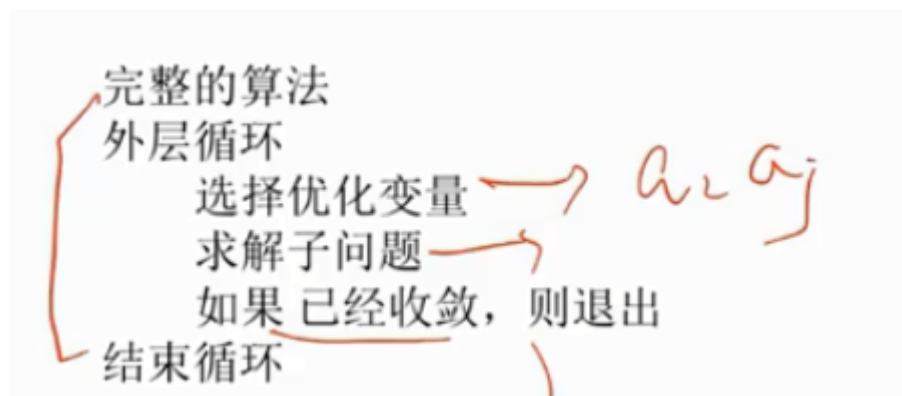


这就求出 α_j 。

15.8 完整的算法

完整的算法
外层循环
 选择优化变量
 求解子问题
 如果 已经收敛，则退出
结束循环

优化变量就两个 α



15.9 实现细节问题

实现细节问题
初始值的设定，一般设置为全0向量
迭代终止的判定规则

- 初始值

$$y^T a = 0$$

$$0 \leq a_i \leq C$$

- 迭代终止

按照KKT条件来判断

$$[\quad] < \quad] <$$

为了保险起见，设置最大迭代次数。

$$\text{max iter}$$

15.10 本集总结

1. why SMO?
2. SMO思想
3. 优化变量的选择
4. 完整的算法
5. 算法细节问题