

# 18 线性模型2

---

## 18 线性模型2

### 18.1 本集内容简介

### 18.2 线性支持向量机简介

### 18.3 L2正则化L1-loss原问题

### 18.4 L2正则化L2-loss原问题

### 18.5 L2正则化对偶问题

### 18.6 L1正则化L2-loss原问题

### 18.7 多类线性支持向量机、

### 18.8 实验

训练模型

模型预测

### 18.9 libsvm和liblinear的比较

### 18.10 实际应用

第一篇文献

第二篇文献

### 18.11 本集总结

## 18.1 本集内容简介

---

前面通过，最大化。

线性支持向量机简介  
L2正则化L1-loss SVC原问题  
L2正则化L2-loss SVC原问题  
L2正则化SVC对偶问题  
L1正则化L2-loss SVC原问题  
多类线性支持向量机  
实验环节  
libsvm和liblinear的比较  
实际应用

L1-loss SVC

这里就不用考虑核函数了

## 18.2 线性支持向量机简介

线性支持向量机

使用非线性核的支持向量机实际应用中存在的问题

线性支持向量机的优点，泛化性能，速度

如果不带有核函数，就是符号函数

Handwritten formula for linear SVM decision function:

$$\text{sgn}(W^T x + b)$$

Below it, with an arrow pointing down:

$$\text{sgn}\left(\sum_{i=1}^L a_i y_i X_i^T X + b\right)$$

如果是核函数，那就用k代替，就变为非线性模型

Handwritten formula for nonlinear SVM decision function using kernel:

$$\text{sgn}\left(\sum_{i=1}^L a_i y_i X_i^T X + b\right)$$

Below it, with an arrow pointing down to the term  $X_i^T X$ :

$(K) \left( \begin{matrix} R^T R \\ \sum \end{matrix} \right)$

如果数据量达到亿，那么用非线性模型是非常慢的，所以一般用线性模型

## 18.3 L2正则化L1-loss原问题

第一种，它的损失函数，前面是正则化，

$$1 - y_i w^T x_i \leq 0 \quad y_i w^T x_i \geq 1 \quad (y_i (w^T x_i + b) \geq 1)$$

如前面讲的支持向量机。

用换元法换下去

$$\min_w \frac{1}{2} w^T w + C \sum_{i=1}^l \max(0, 1 - y_i w^T x_i)$$

hinge loss, 合页损失函数

$$1 - y_i w^T x_i \leq 0 \quad y_i w^T x_i \geq 1$$

$$\xi_i = \max(0, 1 - y_i w^T x_i)$$

$$\min_w \frac{1}{2} w^T w + C \sum_{i=1}^l \xi_i$$

### L2正则化L1-loss SVC原问题

$$\min_w \frac{1}{2} w^T w + C \sum_{i=1}^l \left( \max(0, 1 - y_i w^T x_i) \right)$$

hinge loss, 合页损失函数

$$1 - y_i w^T x_i \leq 0 \quad y_i w^T x_i \geq 1$$

$$\xi_i = \max(0, 1 - y_i w^T x_i)$$

$$\min_w \frac{1}{2} w^T w + C \sum_{i=1}^l \xi_i$$

$$\begin{aligned} \xi_i &= \max(0, 1 - y_i w^T x_i) & \xi &\geq 0 \\ & & \xi_i &\geq 1 - y_i w^T x_i \end{aligned}$$

## 18.4 L2正则化L2-loss原问题

### L2正则化L2-loss SVC原问题

$$\min_w \frac{1}{2} w^T w + C \sum_{i=1}^l \left( \max(0, 1 - y_i w^T x_i) \right)^2$$

可以用可信域牛顿法求解，也可以转化成对偶问题求解

可行域牛顿法

## 18.5 L2正则化对偶问题

不管L1,L2,都可以通过拉格朗日对偶，

我们并没有用梯度下降法，而是坐标下降法，这东西张开就是二次函数，还要考虑吧这样的。

L2正则化SVC对偶问题

$$\min_{\alpha} \frac{1}{2} \alpha^T \bar{Q} \alpha - e^T \alpha$$

$$0 \leq \alpha_i \leq U, i = 1, \dots, l$$

可以用坐标下降法求解

$$\min_z D_{\text{SVM}}(\alpha_1, \dots, \alpha_i + z, \dots, \alpha_l) = \frac{1}{2} Q_{ii} z^2 + \nabla_i D_{\text{SVM}}(\alpha) z + c$$

$$0 \leq \alpha_i + z \leq C$$

$$\nabla_i D_{\text{SVM}}(\alpha) = (Q\alpha)_i - 1 = \sum_{j=1}^l Q_{ij} \alpha_j - 1$$

可以直接求公式解，但要考虑不等式约束

## 18.6 L1正则化L2-loss原问题

介绍下一种，

正则化 原问题，jd托分类，都是对于这个问题，我可以养牛顿法来求解。

## L1正则化L2-loss SVC原问题

$$\min_{\mathbf{w}} \|\mathbf{w}\|_1 + C \sum_{i=1}^l \left( \max(0, 1 - y_i \mathbf{w}^T \mathbf{x}_i) \right)^2$$

可以用坐标下降法求解

$$f(\mathbf{w} + z\mathbf{e}_j) - f(\mathbf{w})$$

$$= |\mathbf{w}_j + z| - |\mathbf{w}_j| + C \sum_{i \in I(\mathbf{w} + z\mathbf{e}_j)} b_i (\mathbf{w} + z\mathbf{e}_j)^2 - C \sum_{i \in I(\mathbf{w})} b_i (\mathbf{w})^2$$

$$= |\mathbf{w}_j + z| + L_j(z, \mathbf{w}) + c$$

$$\approx |\mathbf{w}_j + z| + L'_j(0, \mathbf{w})z + \frac{1}{2}L''_j(0, \mathbf{w})z^2 + c$$

子问题可以采用牛顿法求解

## 18.7 多类线性支持向量机、

多类线性支持向量机

2 1-1

$$\min_{\mathbf{w}_m, \xi_i} \frac{1}{2} \sum_{m=1}^k \mathbf{w}_m^T \mathbf{w}_m + C \sum_{i=1}^l \xi_i$$

$$\mathbf{w}_{y_i}^T \mathbf{x}_i - \mathbf{w}_m^T \mathbf{x}_i \geq e_i^m - \xi_i, i = 1, \dots, l$$

$$e_i^m = \begin{cases} 0 & y_i = m \\ 1 & y_i \neq m \end{cases}$$

$$\arg \max_{m=1, \dots, k} \mathbf{w}_m^T \mathbf{x}$$

用拉格朗日对偶转化

对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{m=1}^k \|\mathbf{w}_m\|^2 + \sum_{i=1}^l \sum_{m=1}^k e_i^m \alpha_i^m$$

$$\sum_{m=1}^k \alpha_i^m = 0, \forall i = 1, \dots, l$$

$$\alpha_i^m \leq C_{y_i}^m, \forall i = 1, \dots, l, m = 1, \dots, k$$

$$\mathbf{w}_m = \sum_{i=1}^l \alpha_i^m \mathbf{x}_i, \forall m, \quad \alpha = [\alpha_1^1, \dots, \alpha_1^k, \dots, \alpha_l^1, \dots, \alpha_l^k]^T$$

$$C_{y_i}^m = \begin{cases} 0 & y_i \neq m \\ C & y_i = m \end{cases}$$

采用分治法求解

对偶问题用分治法求解

## 18.8 实验

使用liblinear

### 训练模型

生成的模型文件是a1a\_model\_svm

```
train -s 3 a1a a1a_model_svm
```

```
.....  
optimization finished, #iter = 169  
Objective value = -540.863528  
nSV = 608
```

模型文件的内容如下图

```
nr_class 2  
label 1 -1  
nr_feature 119  
bias -1  
w  
-0.6712184355140607  
-0.4280933369941015
```

- 类别数2
- label 1 -1
- 特征
- 偏置向量是负一 -1
- 权重矩阵

。

$$W^T x \rightarrow 20 + 1$$



## 模型预测

前面训练完模型之后，我们用预测模型进行预测，测试样本就是a1a.t 文件。

使用前面训练的模型

```
libsvm predict a1a.t a1a_model_svm
```

预测结果保存到

```
libsvm a1a_predict_svm
```

精度和前面用RBF的差不多一样。

输入命令之后，显示如下

```
libsvm predict a1a.t a1a_model_svm a1a_predict_svm
```

```
E:\代码\liblinear\liblinear-2.11\liblinear-2.11\windows>libsvm predict a1a.t a1a_model_svm a1a_predict_svm
Accuracy = 83.8125% (25945/30956)
```

## 18.9 libsvm和liblinear的比较

<https://www.csie.ntu.edu.tw/~cjlin/liblinear/>

<https://www.csie.ntu.edu.tw/~cjlin/libsvm/>

对于svm

libsvm支持非线性核，可以实现非线性模型；liblinear中只有线性核，是线性模型

liblinear可以直接得到w和b，而libsvm不行

求解算法不同，libsvm采用的是SMO算法；liblinear采用的是可信域牛顿法，坐标下降法

$$\text{sgn}\left(\sum_{i=1}^L a_i y_i k(x_i^T x) + b\right)$$

$$\text{sgn}(w^T x)$$

前面在剖析libsvm模型的时候，

liblinear可以直接得到w 和b,而libsvm不行。

求解算法不同，libsvm采用的是SMO算法，而liblinear采用的是可信域牛顿法，坐标下降法。

可以自己研究这两个算法

Xiang-Rui Wang: versions 1.0-1.1.

张开伟：L1和L2损失双SVM，多级（Crammer&Singer），L1正则化分类器的双坐标下降。

Cho-Jui Hsieh：L1和L2损失双SVM，多级（Crammer&Singer），L1正则化分类器的双坐标下降。

范荣恩：所有问题的大帮手。

Guo-Xun Yuan and Chia-Hu Ho: L1-regularized classifiers.

Hsiang-Fu Yu和Fang-Lan Huang：L2正则化逻辑回归的双坐标下降

Hsiang-Fu Yu：python界面

Chia-Hua Ho：线性支持向量回归的求解器

Bo-Yu Chu和Chia-Hua Ho：参数选择代码

Mu-Chu Lee和Wei-Lin Chiang：求解器中两个主要操作（点和axpy）的抽象。将牛顿上的两个矩阵向量乘法组合成一个。

Chih-Yang Hsieh和Ya Zhu：基于原始的Newton方法（版本2.11）中改进的信任区域更新规则的代码

Hsiang-Fu Yu和Hsin-Yuan Huang：python界面中的scipy支持（版本2.11）

在实际应用中，怎么挑这两个库呢？

如果样本量比较小，用libsvm，精度较高

如果你的特征向量维数很高，训练样本也很多，则选用liblinear

## 18.10 实际应用

### 实际应用




[1] Navneet Dalal, Bill Triggs. Histograms of oriented gradients for human detection. computer vision and pattern recognition. 2005.

[2] R. Girshick, J. Donahue, T. Darrell, J. Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014.

### 第一篇文献


运用非常高的是第一篇文献。

HOG + L-SVM做行人检测



通过一个活动框，从左到右，从上到下，依次滑块，判断物体是不是行人，是个二分类问题。

为了检测行人的大小，经常将框的大小进行缩放，在判断是不是行人。



运算量非常大。

如果用高斯核，精度会高一点，但是速度你是受不了的。

所以只能选用线性支持向量机。

第一篇文章的核心创新点就是基于HOG特征。


传统的机器学习都是这样的。

## 第二篇文献

---

是这个领域做通用目标检测的文章，

用深度学习来做图像检测，CNN.



得到这样的特征之后，紧接着对图像进行分类。是自行车，还是汽车，还是行人。都是用线性的支持向量机来做的。



如果特征的维度很高，样本数量很多，就只能用线性支持向量机来做。效果也是不错的，保持最大化分类间隔。

## 18.11 本集总结

1. (L-SVM)

2. hinge loss

L2 [21] → 4  
L2 [22] → 8  
L1 [23]

3. 0

4. (libsvm liblinear)  
S. ... HOG of L-SVM  
L-